

Регрессия по функциональным данным через линейные функционалы

Карташов Игорь Олегович
Группа J3212

5 июня 2026 г.

Аннотация

В данной работе мы рассматриваем задачу регрессии по функциональным данным. Каждый объект задается не вектором признаков, а функцией $x(t)$ на интервале $[0, 1]$. Для перехода к обычной регрессии функция заменяется набором интегральных признаков. Эксперименты проведены на синтетических данных с известной истинной зависимостью, поэтому можно оценить не только качество прогноза, но и восстановление весовой функции модели.

1 Постановка задачи

Пусть задан набор наблюдений

$$\{(x_i(t), y_i)\}_{i=1}^n,$$

где $x_i(t)$ — функция на интервале $[0, 1]$, а $y_i \in \mathbb{R}$ — числовой ответ. Требуется построить модель, которая по функции $x_i(t)$ предсказывает y_i .

Так как функция не является конечномерным вектором, сначала строятся признаки

$$z_{ik} = \int_0^1 x_i(t) \varphi_k(t) dt,$$

где $\varphi_k(t)$ — выбранная весовая функция. После этого модель принимает вид

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{ik}.$$

Цель работы — сравнить разные системы функционалов, изучить влияние числа признаков и регуляризации, а также проверить устойчивость модели к шуму и изменению сетки.

2 Теоретическая основа

Функции рассматриваются как элементы пространства $L^2[0, 1]$ со скалярным произведением

$$\langle f, g \rangle = \int_0^1 f(t)g(t) dt.$$

Тогда признак можно записать в виде

$$z_{ik} = \langle x_i, \varphi_k \rangle.$$

Интегральный функционал

$$L_\varphi(x) = \int_0^1 x(t)\varphi(t) dt$$

линеен, потому что

$$L_\varphi(x_1 + x_2) = L_\varphi(x_1) + L_\varphi(x_2), \quad L_\varphi(\alpha x) = \alpha L_\varphi(x).$$

В работе используются три системы функционалов:

1. индикаторы равных подотрезков;
2. полиномиальные функции $1, t, t^2, \dots$;
3. нормированный тригонометрический базис

$$1, \sqrt{2} \sin(2\pi t), \sqrt{2} \cos(2\pi t), \dots$$

3 Синтетические данные

Для экспериментов были сгенерированы синтетические функциональные наблюдения:

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t),$$

где a_i, b_i, c_i выбирались случайно, а $\varepsilon_i(t)$ — шум в функции.

Ответ задавался через истинную весовую функцию:

$$y_i = \int_0^1 x_i(t)w_{\text{true}}(t) dt + \eta_i,$$

где

$$w_{\text{true}}(t) = 2 \sin(2\pi t) - t.$$

В эксперименте использовались параметры:

$$n = 500, \quad p = 200, \quad \sigma_x = 0.10, \quad \sigma_y = 0.10.$$

Доля тестовой выборки составляла 25%.

4 Численная реализация

Функции задавались на равномерной сетке $t_1, \dots, t_p \in [0, 1]$. Интегралы вычислялись методом трапеций:

$$\int_0^1 x_i(t)\varphi_k(t) dt \approx \text{trapz}(x_i(t)\varphi_k(t)).$$

В результате строилась матрица признаков

$$Z = (z_{ik}) \in \mathbb{R}^{n \times m}.$$

Для учета свободного коэффициента к матрице признаков добавлялся столбец единиц.

5 Линейная модель и МНК

После построения признаков задача сводится к линейной регрессии:

$$\hat{y} = X\beta.$$

Коэффициенты МНК находятся из задачи

$$Q(\beta) = (y - X\beta)^T(y - X\beta) \rightarrow \min.$$

Нормальные уравнения имеют вид

$$X^T X \hat{\beta} = X^T y.$$

При обратимости $X^T X$ решение записывается как

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$

В реализации дополнительно использовалась псевдообратная матрица, чтобы не зависеть от обратимости $X^T X$.

6 Интерпретация через весовую функцию

Модель можно записать так:

$$\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle.$$

Введем

$$w(t) = \sum_{k=1}^m \beta_k \varphi_k(t).$$

Тогда

$$\sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle = \left\langle x, \sum_{k=1}^m \beta_k \varphi_k \right\rangle = \langle x, w \rangle.$$

Значит,

$$\hat{y}(x) = \beta_0 + \langle x, w \rangle.$$

Функция $w(t)$ показывает, какие части и компоненты входной функции сильнее влияют на прогноз.

7 Эксперименты и результаты

7.1 Сгенерированные функции и истинная весовая функция

На рисунке 1 показаны примеры сгенерированных функций $x_i(t)$.




Рис. 1: Примеры синтетических функциональных наблюдений $x_i(t)$.

На рисунке 2 показана истинная весовая функция $w_{\text{true}}(t)$.




Рис. 2: Истинная весовая функция $w_{\text{true}}(t) = 2 \sin(2\pi t) - t$.

7.2 Пример систем функционалов и проверка ортонормированности

На рисунке 3 показан пример второй функции $\varphi_2(t)$ для трех наборов функционалов. Это позволяет увидеть, что разные системы по-разному описывают функцию: локально, через полиномиальный тренд или через периодическую компоненту.




Рис. 3: Пример второй функции из каждого набора функционалов.

Для тригонометрического базиса была построена матрица Грама:

$$G_{k\ell} = \langle \varphi_k, \varphi_\ell \rangle.$$

Результат показан на рисунке 4. Максимальное отклонение от единичной матрицы в эксперименте равно 0.000000, то есть система численно ортонормирована.




Рис. 4: Матрица Грама для тригонометрического базиса.

7.3 Проверка линейности и МНК

Для одного функционала была выполнена численная проверка линейности. Ошибка аддитивности и ошибка однородности оказались равны нулю с точностью вычислений:

$$|L(x_1 + x_2) - L(x_1) - L(x_2)| = 0, \quad |L(\alpha x) - \alpha L(x)| = 0.$$

Также была проверена ручная реализация МНК. Коэффициенты, полученные через псевдообратную матрицу, совпали с коэффициентами `sklearn LinearRegression`. На тестовой выборке для базового тригонометрического набора при $m = 8$ получено:

$$MSE = 0.010344, \quad RMSE = 0.101706, \quad R^2 = 0.993591.$$

7.4 Сравнение систем функционалов при фиксированном m

При фиксированном числе функционалов $m = 8$ были сравнены три системы признаков. Результаты приведены в таблице 1 и на рисунке 5.

Таблица 1: Сравнение систем функционалов при $m = 8$

Система	MSE test	RMSE test	R^2 test	$\ \beta\ _2$
Тригонометрический базис	0.010344	0.101706	0.993591	1.878499
Индикаторы	0.010437	0.102162	0.993533	5.418945
Полиномы	0.010540	0.102667	0.993469	48360.978220




Рис. 5: Сравнение RMSE для разных систем функционалов при $m = 8$.

При $m = 8$ лучшее качество показал тригонометрический базис. Разница по RMSE небольшая, но полиномиальный базис имеет очень большую норму коэффициентов, что указывает на плохую устойчивость.

7.5 Влияние числа функционалов

Далее число функционалов изменялось:

$$m \in \{2, 3, 4, 5, 8, 12, 16, 20, 30\}.$$

Результат показан на рисунке 6.




Рис. 6: Зависимость RMSE от числа функционалов m .

Лучшие значения по подбору m :

Таблица 2: Лучшее значение m для каждой системы функционалов

Система	Лучшее m	RMSE test	R^2 test
Индикаторы	20	0.100671	0.993720
Полиномы	30	0.101063	0.993671
Тригонометрический базис	2	0.101111	0.993665

После подбора числа функционалов лучшим вариантом стали индикаторы при $m = 20$. Это показывает, что даже простой локальный базис может хорошо работать, если взять достаточно разбиений.

7.6 Восстановление весовой функции

Для каждого набора функционалов была восстановлена функция

$$\hat{w}(t) = \sum_{k=1}^m \hat{\beta}_k \varphi_k(t).$$

Сравнение с истинной функцией $w_{\text{true}}(t)$ показано на рисунке 7.




Рис. 7: Сравнение истинной и восстановленных весовых функций при $m = 16$.

Таблица 3: Ошибка восстановления весовой функции

Система	MSE_w	$\ \beta\ _2$
Полиномы	3.124801	$4.789373 \cdot 10^9$
Индикаторы	5.972623	11.965510
Тригонометрический базис	6.470258	3.066461

По ошибке восстановления $w(t)$ полиномиальный набор оказался лучше, но его коэффициенты имеют крайне большую норму. Поэтому этот результат нельзя считать устойчивым.

7.7 Ridge-регрессия

Для повышения устойчивости использовалась ridge-регрессия:

$$Q_\lambda(\beta) = (y - X\beta)^T(y - X\beta) + \lambda\|\beta\|_2^2.$$

Решение имеет вид

$$\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y.$$

Сначала была взята регуляризация $\lambda = 1$ при $m = 20$. Результаты сравнения с обычным МНК приведены в таблице 4.


Таблица 4: Сравнение OLS и Ridge при $m = 20$

Система	Модель	RMSE test	R^2 test	$\ \beta\ _2$
Индикаторы	OLS	0.100671	0.993720	14.902310
Индикаторы	Ridge	0.155031	0.985108	7.038170
Полиномы	OLS	0.102108	0.993540	$3.039836 \cdot 10^{10}$
Полиномы	Ridge	0.138008	0.988199	5.111943
Тригонометрический базис	OLS	0.101363	0.993634	3.312277
Тригонометрический базис	Ridge	0.101775	0.993582	1.722180

При $\lambda = 1$ регуляризация сильно уменьшает норму коэффициентов, особенно для полиномиального базиса. При этом для индикаторов и полиномов качество ухудшается, то есть такая регуляризация слишком сильная. Для тригонометрического базиса качество почти не меняется.

7.8 Зависимость от параметра регуляризации

Затем параметр λ перебирался на логарифмической сетке от 10^{-4} до 10^3 . На рисунке 8 показана зависимость RMSE от λ , а на рисунке 9 — зависимость нормы коэффициентов.

Рис. 8: Зависимость RMSE ridge-регрессии от параметра λ .




Рис. 9: Влияние λ на норму коэффициентов модели.

Лучшие значения λ :

Таблица 5: Лучшие значения λ для ridge-регрессии			
Система	Лучшее λ	RMSE test	R^2 test
Индикаторы	0.000383	0.100436	0.993750
Полиномы	0.002873	0.101960	0.993559
Тригонометрический базис	0.021544	0.100856	0.993697

Лучшее качество после подбора λ получили индикаторы: $RMSE = 0.100436$, $R^2 = 0.993750$.

7.9 Устойчивость к шуму

Для проверки устойчивости менялся уровень шума в функциях:

$$\sigma_x \in \{0.00, 0.05, 0.10, 0.20, 0.40\}.$$

Для каждого значения проводилось 5 повторов. Использовался тригонометрический базис при $m = 16$.




Рис. 10: Устойчивость OLS и Ridge к шуму в функциях.

Таблица 6: Устойчивость к шуму в функциях

Модель и σ_x	Средний RMSE	Std RMSE	Средний R^2
OLS, 0.00	0.102212	0.004743	0.994212
Ridge, 0.00	0.102647	0.005506	0.994152
OLS, 0.10	0.103487	0.003669	0.994084
Ridge, 0.10	0.102605	0.005453	0.994156
OLS, 0.40	0.103359	0.003635	0.994102
Ridge, 0.40	0.102527	0.005026	0.994176

В этом эксперименте качество менялось слабо. Это связано с тем, что зависимость от ответа задавалась через интеграл, а интегрирование частично сглаживает шум.

7.10 Устойчивость к изменению сетки

Также исследовалась зависимость качества от числа точек сетки:

$$p \in \{25, 50, 100, 200, 500\}.$$

Результат показан на рисунке 11.




Рис. 11: Устойчивость качества к изменению плотности сетки.

Таблица 7: Устойчивость к изменению числа точек сетки

p	Модель	RMSE test	R^2 test
25	OLS	0.108607	0.992819
25	Ridge	0.106771	0.993060
50	OLS	0.112329	0.991905
50	Ridge	0.109484	0.992310
100	OLS	0.108346	0.992667
100	Ridge	0.103489	0.993309
200	OLS	0.101744	0.993586
200	Ridge	0.101777	0.993582
500	OLS	0.097498	0.994053
500	Ridge	0.090657	0.994858

При увеличении числа точек сетки качество в целом улучшается, так как интегралы вычисляются точнее. На самой плотной сетке лучший результат показала ridge-регрессия.

8 Сводные результаты

Сводная таблица лучших настроек приведена ниже.

Таблица 8: Сводные результаты экспериментов

Эксперимент	Лучшая настройка	RMSE test	R^2 test
Фиксированное m	Тригонометрический базис, $m = 8$	0.101706	0.993591
Подбор m	Индикаторы, $m = 20$	0.100671	0.993720
Ridge: подбор λ	Индикаторы, $m = 20$, $\lambda = 0.000383$	0.100436	0.993750

9 Обсуждение

При фиксированном числе функционалов $m = 8$ лучший результат показал тригонометрический базис. Это ожидаемо, так как синтетические функции содержат синус и косинус. Однако после подбора числа функционалов и параметра регуляризации лучшим оказался индикаторный базис. Разница в качестве между лучшими моделями небольшая, поэтому важны не только RMSE и R^2 , но и устойчивость коэффициентов.

Полиномиальные признаки дают близкое качество прогноза, но имеют очень большие нормы коэффициентов и большое число обусловленности. Это говорит о нестабильности модели. Ridge-регрессия заметно уменьшает нормы коэффициентов, но слишком большое значение λ может ухудшить качество.

Восстановление весовой функции показывает интерпретируемость подхода: модель можно анализировать не только как предсказатель, но и как функцию $w(t)$, которая показывает вклад разных частей входного сигнала.

10 Заключение

В работе была рассмотрена регрессия по функциональным данным через линейные интегральные функционалы. Функции $x_i(t)$ были переведены в конечномерные признаки, после чего применялись МНК и ridge-регрессия.

Эксперименты показали, что выбор системы функционалов влияет на качество и устойчивость модели. При фиксированном $m = 8$ лучше всего сработал тригонометрический базис. При подборе числа функционалов и параметра регуляризации лучший результат дали индикаторы подотрезков. При этом полиномиальный базис оказался менее устойчивым из-за больших коэффициентов.

Также было показано, что модель можно интерпретировать через восстановленную весовую функцию $w(t)$. Это является главным преимуществом подхода: результат остается не только численно точным, но и содержательно объяснимым.

11 Репозиторий и воспроизводимость

Код вычислительного эксперимента представлен в виде Jupyter Notebook. Ссылка на репозиторий с кодом:

<https://github.com/IGK-arch/Regression-on-functional-data-through-linear-functionals>

12 Политика использования ИИ

Инструменты искусственного интеллекта использовались как вспомогательное средство для структурирования отчёта, проверки формулировок и организации вычислительного эксперимента. Численные результаты, графики и выводы основаны на выполненном автором коде и проверены в ноутбуке. Заимствованные формулировки не выдаются за самостоятельные теоретические результаты; основная часть работы представляет собой индивидуальный вычислительный эксперимент.

Список литературы

- [1] Взаимодействие с ИИ рамках чата с ChatGPT: <https://chatgpt.com/share/6a25540b-27e0-83eb-a243-58a22d6f0767>